



Pautas de la actividad



Semillas de trigo

Clasificación de 3 variedades de trigo (Kama, Rosa, Canadiense) según 7 medidas del grano.

Clasificación

Objetivo: clase

03/10/2026 07:16





Pautas de la actividad

Se cumplen 7 de 7 pautas. Cada una muestra su resultado calculado sobre los datos reales del dataset y una conclusión.

Pauta 1: Cargar y explorar el dataset con Pandas (cumplida)

Resultado: 7 características · 0 nulos

Características: área, perímetro, compacidad, largo_grano, ancho_grano, coef_asimetría, largo_surco

Filas	Características	Variable objetivo	Valores nulos
210	7	clase (Canadiense 70 · Kama 70 · Rosa 70)	0

Conclusión: El dataset tiene 210 registros y 7 características numéricas. No hay valores nulos en ninguna columna. Está equilibrado: Canadiense 70 · Kama 70 · Rosa 70.

Pauta 2: Separar la variable objetivo y normalizar con StandardScaler (cumplida)

Resultado: X: 210×7 · y: 210

área	Antes (valores reales)	Después de StandardScaler
Media	14,848	0,000
Desviación estándar	2,903	1,000

Conclusión: Se separaron las 7 características (X) de la variable «clase» (y). Después de StandardScaler cada característica queda con media 0 y desviación 1 (área pasó de media 14,85 a 0,00): así ninguna pesa más que otra al entrenar, algo importante para K-Vecinos, que compara distancias.

Pauta 3: NumPy: vectores, matrices, producto punto, norma y sistema de ecuaciones (cumplida)

Resultado: $v1 \cdot v2 = 444,06$

Operación (registros 1 y 2)	Resultado
Producto punto $v1 \cdot v2$ (np.dot)	444,055
Norma de $v1$ (np.linalg.norm)	21,304
Norma de $v2$	20,844



Operación (registros 1 y 2)	Resultado
Distancia entre v1 y v2	0,466
Matriz A (3 registros × 3 medidas) y su transpuesta	A × transpuesta de A, calculada
Sistema $A \cdot w = b$, con $b = \text{largo_grano}$ (<code>np.linalg.solve</code>)	$w = [1,215; -0,906; 0,778]$

Conclusión: Cada grano es un vector con sus medidas. Los dos primeros están a una distancia de 0,466: es la cuenta que usa K-Vecinos para saber cuáles se parecen. Al multiplicar A por la solución se vuelve a obtener b, así que el sistema está bien resuelto.

Pauta 4: Media, mediana, varianza y desviación de área y perímetro (cumplida)

Resultado: área: media 14,85

Variable	Media	Mediana	Varianza NumPy	Varianza manual	Desviación NumPy	Desviación manual
área	14,848	14,355	8,426	8,426	2,903	2,903
perímetro	14,559	14,320	1,697	1,697	1,303	1,303

Conclusión: La media de área (14,85) es mayor que su mediana (14,36): hay algunos granos grandes que tiran el promedio para arriba. La varianza y la desviación de área calculadas a mano dan exactamente lo mismo que NumPy. Comparada con su propio promedio, área es la que más varía.

Pauta 5: Valores atípicos de área (dos desviaciones estándar) (cumplida)

Resultado: 4 atípicos


Media - 2σ	Media + 2σ	Cantidad	Valores atípicos
9,04	20,65	4	20,71 · 20,88 · 20,97 · 21,18

Conclusión: Con el criterio de dos desviaciones estándar, 4 de 210 granos (1,9 %) quedan fuera del rango [9,04; 20,65], todos por encima: son granos muy grandes, no errores de medición.



Pauta 6: Histograma de área y dispersión área contra perímetro (cumplida)

Resultado: 2 gráficos



Conclusión: Área y perímetro van casi juntos (correlación 0,99). En la dispersión se ven las 3 variedades: los granos de Rosa son los más grandes, los de Canadiense los más chicos y los de Kama quedan en el medio.

Pauta 7: K-Vecinos contra Árbol de Decisión (Accuracy) (cumplida)

Resultado: K-Vecinos 88,10 % · Árbol 92,86 %

Modelo	Accuracy
K-Vecinos (KNeighborsClassifier)	88,10 %
Árbol de Decisión (DecisionTreeClassifier)	92,86 %

Conclusión: Gana el Árbol de Decisión por 4,76 puntos: aciertan alrededor de 9 de cada 10 granos del grupo de prueba, que no se usó para entrenar.

Conclusión general: El dataset está completo; área y perímetro ayudan a separar las 3 variedades, y los dos modelos las clasifican con buen acierto (K-Vecinos 88,10 % · Árbol 92,86 %).